

# Flujo ETL multifuente y Data Warehouse dimensional del sistema de banca privada del Ecuador

Informe técnico · Taller individual, semana 1

**Fuente:** Superintendencia de Bancos del Ecuador, boletines de colocaciones y captaciones de la banca privada · **Periodo:** enero 2024 – mayo 2026 (29 cortes mensuales) · **Fecha:** 30/08/2026

## 1. Objeto y alcance


Se construye un flujo ETL que integra cuatro fuentes de datos heterogéneas y las consolida en un Data Warehouse dimensional en modelo estrella, con seis dimensiones y una tabla de hechos. El conjunto de entrada consta de 18 libros Excel de la Superintendencia de Bancos del Ecuador, con el detalle mensual de la cartera de crédito y de los depósitos de las 26 razones sociales de la banca privada, desagregado por cantón. La infraestructura se ejecuta en contenedores Docker.

|                             |                               |                              |                          |
|-----------------------------|-------------------------------|------------------------------|--------------------------|
| 4                           | 6 + 1                         | 176.990                      | 122                      |
| Fuentes de datos integradas | Dimensiones y tabla de hechos | Registros de hechos cargados | Nodos del flujo de KNIME |

## 2. Arquitectura y fuentes de datos

La arquitectura se organiza en tres capas: aterrizaje ( `staging` ), almacén dimensional ( `dw` ) y capa de explotación OLAP. Cada fuente se materializa en una tecnología distinta, de modo que el flujo resuelve diferencias de protocolo de conexión, formato y esquema.

| Código      | Tecnología | Alimenta    | Filas   |
|-------------|------------|-------------|---------|
| F1_POSTGRES | PostgreSQL | Hechos      | 122.217 |
| F2_MYSQL    | MySQL      | Dimensiones | 177     |
| F3_EXCEL    | Excel XLSX | Hechos      | 45.341  |
| F4_CSV      | CSV        | Hechos      | 9.432   |




**Figura 1.** Arquitectura de extremo a extremo.

Cada libro del regulador contiene una hoja de presentación, con subtotales embebidos, y una hoja **BASE** en formato largo. El flujo lee la hoja **BASE**; la de presentación duplicaría los importes al mezclar detalle con totales. El perfilado previo registró cero valores nulos y cero importes negativos, y verificó que la identidad **TOTAL = POR VENCER + NO DEVENGA + VENCIDA** se cumple en las 54.773 filas de cartera.

### 3. Modelo dimensional

El modelo unifica colocaciones y captaciones en una única tabla de hechos y emplea la dimensión **dim\_tipo\_operacion** como eje discriminador, lo que permite calcular indicadores que cruzan el activo y el pasivo de la entidad sin unir dos tablas de hechos. El grano es un registro por mes de corte, entidad, cantón y producto financiero; corresponde a un *snapshot* periódico mensual, por lo que las métricas de saldo son semiaditivas en el tiempo.



**Figura 2.** Modelo estrella. Todas las claves primarias son subrogadas.

**Jerarquías:** tiempo (año → semestre → trimestre → mes); entidad (grupo de tamaño → perfil de negocio → entidad); geografía (región → provincia → cantón); producto (familia → subfamilia → producto). Habilitan las operaciones de *drill-down*, *roll-up* y *slice and dice*. La vista **dw.v\_cubo\_banca** expone el modelo desnormalizado y cuatro vistas adicionales materializan los indicadores de negocio.

| Objeto                  | Filas   |
|-------------------------|---------|
| dim_tiempo              | 29      |
| dim_entidad             | 26      |
| dim_geografia           | 126     |
| dim_producto            | 19      |
| dim_tipo_operacion      | 2       |
| dim_fuente_datos        | 4       |
| fact_saldos_financieros | 176.990 |

## 4. Transformación y limpieza

El perfilado identificó seis incidencias en los archivos de origen.

| Incidencia                                                           | Tratamiento                                                                                                        |
|----------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| Espacios dobles en la razón social ( BP BANCO DESARROLLO... )        | <code>regexReplace(strip(col), "\s+", " ")</code>                                                                  |
| Prefijos BP y BANCO y forma societaria S.A. heterogéneos             | Derivación de un nombre comercial homogéneo, base de la clave <code>cod_entidad</code>                             |
| Diácríticos en ATLÁNTIDA , CAÑAR , TSÁCHILAS                         | Normalización NFD en la clave; las tildes se conservan en el nombre de presentación                                |
| Los archivos de cartera no incluyen la columna REGIÓN                | Join contra el catálogo geográfico alojado en MySQL; la dimensión se construye con dos fuentes                     |
| ZONA NO DELIMITADA / LAS GOLONDRINAS sin región asignable (58 filas) | Miembro NO DEFINIDA y bandera <code>es_registro_desconocido</code> ; los importes permanecen en la tabla de hechos |
| Banco Amibank con dos razones sociales, activa y en liquidación      | Dimensión lentamente cambiante de tipo 2: una clave de negocio y dos versiones con vigencia acotada                |

| Ver. | Nombre en el origen                | Estado         | Vigente desde | Vigente hasta |
|------|------------------------------------|----------------|---------------|---------------|
| 1    | BANCO AMIBANK S.A.                 | ACTIVA         | 2024-01-31    | 2025-01-30    |
| 2    | BANCO AMIBANK S.A., EN LIQUIDACION | EN LIQUIDACION | 2025-01-31    | 9999-12-31    |

Durante la resolución de claves subrogadas, cada hecho se asocia a la versión vigente en su fecha de corte. Se derivan además `saldo_improductivo` (cartera que no devenga intereses más cartera vencida) y `saldo_promedio_cliente` (saldo entre número de clientes). El filtro de calidad descarta filas sin fecha, sin entidad o con saldo negativo; el número de filas descartadas es cero.

## 5. Implementación en KNIME

El flujo `ETL_Banca_Ecuador.knwf` implementa el proceso con 122 nodos y 135 conexiones en quince tipos de nodo. Su ejecución carga el modelo estrella en el esquema `dw_knime`.

| Bloque            | Nodos | Composición                                                                                                                           |
|-------------------|-------|---------------------------------------------------------------------------------------------------------------------------------------|
| A. Extracción     | 23    | 2 conectores de base de datos, 7 lectores de consulta, 12 lectores de Excel y 1 lector de CSV                                         |
| B. Transformación | 30    | 25 <i>String Manipulation</i> , 4 <i>Math Formula</i> , 4 <i>Rule Engine</i> , 4 <i>Rule-based Row Filter</i> y 13 <i>Concatenate</i> |
| C. Dimensiones    | 20    | Carga de las seis dimensiones; <code>dim_tiempo</code> se deriva dentro del flujo                                                     |
| D. Hechos         | 19    | 8 <i>Joiner</i> para la sustitución de claves de negocio por subrogadas, incluida la resolución SCD-2                                 |


## 6. Validación

El script `etl/03_validacion.sql` ejecuta diez pruebas sobre el almacén cargado.

| Prueba                                                       | Resultado                                                                |
|--------------------------------------------------------------|--------------------------------------------------------------------------|
| Integridad referencial (6 claves foráneas)                   | Cero registros huérfanos                                                 |
| Conciliación <code>staging</code> ↔ <code>dw</code>          | 122.217 filas y USD 1.558.549 millones en ambos                          |
| Identidad contable TOTAL = POR VENCER + NO DEVENGA + VENCIDA | Cero filas la incumplen                                                  |
| Cobertura temporal                                           | 29 cortes mensuales consecutivos                                         |
| Filas descartadas por el filtro de calidad                   | Cero                                                                     |
| Conciliación <code>dw</code> ↔ <code>dw_knime</code>         | Idéntico número de filas e importes en las siete tablas (176.990 hechos) |

## 7. Resultados del análisis

Las captaciones registran una tasa de crecimiento superior a la de las colocaciones durante todo el periodo, y la diferencia entre ambas series se amplía de forma sostenida.



**Figura 3.** Saldos trimestrales del sistema, en miles de millones de dólares. Cortes de fin de trimestre.

El índice de morosidad del sistema se mantiene estable (2024: 3,57 % · 2025: 3,18 % · 2026: 3,16 %). La dispersión entre segmentos es amplia: el microcrédito registra un índice seis veces superior al del crédito

productivo. Cuatro entidades concentran el 66,9 % de las captaciones; la clasificación por tamaño se deriva de los propios datos mediante un criterio de Pareto sobre el volumen acumulado.




Figura 4. Cartera improductiva sobre cartera bruta por segmento, 2026.

| Grupo   | Bancos | Mercado |
|---------|--------|---------|
| GRANDE  | 4      | 66,9 %  |
| MEDIANO | 3      | 20,6 %  |
| PEQUEÑO | 16     | 12,5 %  |

## 8. Conclusiones

1. El flujo integra cuatro tecnologías de origen distintas en un modelo estrella único y carga 176.990 registros de hechos.
2. La normalización de claves y la historificación SCD-2 consolidan 26 razones sociales en 25 entidades con 26 versiones, lo que preserva la continuidad de las series históricas.
3. La dimensión geográfica se completa con datos de dos fuentes, dado que ninguna contiene la totalidad de los atributos.
4. Las implementaciones en KNIME y en Python producen resultados idénticos, y la contenerización permite reproducir el proceso en cualquier equipo con Docker.